



Машинное обучение

Лекция 4:

Линейная регрессия

Докладчик: Иван Горохов



Задача машинного обучения

$\mathbb{X}$ — пространство объектов, $\mathbb{Y}$ — пространство ответов

$x = (x_1, \dots, x_d)$ — вектор признаков

$\mathbb{D} = \{(x_i, y_i)\}_{i=1}^{\ell}$ — обучающая выборка

$a(x)$ — алгоритм (модель)

$Q(a, \mathbb{D})$ — функционал качества (ошибки)

A — множество допустимых алгоритмов

Цель: найти $a = \arg \min_{a \in A} Q(a, \mathbb{D})$



Задача регрессии и MSE

Рассматриваем случай, когда:

$\mathbb{Y} = \mathbb{R}$ (ответ — число)

$x \in \mathbb{R}^d, y \in \mathbb{R}$

Функционал ошибки (Mean Squared Error):

$$Q(a, \mathbb{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2$$



Линейная модель

Основная формула:


$$a(x) = w_0 + \sum_{j=1}^d w_j x_j$$

Введем фиктивный признак:

$$x_0 \equiv 1$$

В векторном виде:

$$a(x) = \sum_{j=0}^d w_j x_j = \langle w, x \rangle$$





Матричная форма

Обозначим матрицу "Объекты-Признаки":

$$X = \begin{pmatrix} x_{11} & \dots & x_{1d} \\ \vdots & \ddots & \vdots \\ x_{\ell 1} & \dots & x_{\ell d} \end{pmatrix}, \quad y = \begin{pmatrix} y_1 \\ \vdots \\ y_\ell \end{pmatrix}$$

Задача минимизации:

$$Q(w, \mathbb{D}) = \frac{1}{\ell} \|Xw - y\|^2 \rightarrow \min_w$$



Оценка параметра

Запишем MSE в матричной форме для отыскания минимума через производную:

$$MSE(X, y, w) = \frac{1}{n} (y - Xw)^T (y - Xw).$$

Возьмем производную по искомому параметру:

$$\frac{\partial MSE(X, y, w)}{\partial w} = -\frac{2}{n} X^T (y - Xw)$$

И приравняем ее к нулю:

$$-\frac{2}{n} X^T (y - Xw) = 0.$$

Тогда аналитическая оценка параметра равна:

$$\hat{w} = (X^T X)^{-1} X^T y.$$



Мультиколлинеарность

Если столбцы матрицы почти линейно зависимы, то говорят что матрица плохо обусловлена. Это называется *проблемой мультиколлинеарности*. Она ведет к:

- большому разбросу по абсолютной величине и знаку у коэффициентов $\hat{w}$;
- значение $\|\hat{w}\|$ будет слишком велико;
- *неустойчивому обучению* (добавление/удаление объектов сильно меняет $\hat{w}$);
- *неустойчивому решению* (малое изменение данных сильно меняет ответ);
- возникновению сильного переобучения.

В таких случаях задача становится некорректно поставленной.



Регуляризация

L2 (Ridge):

$$Q_{L2}(w, \mathbb{D}) = \frac{1}{\ell} \|Xw - y\|^2 + \lambda \|w\|_2^2$$

L1 (Lasso):

$$Q_{L1}(w, \mathbb{D}) = \frac{1}{\ell} \|Xw - y\|^2 + \lambda \|w\|_1$$

ElasticNet:

$$Q_{EN}(w, \mathbb{D}) = \frac{1}{\ell} \|Xw - y\|^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$$



Градиентный спуск

Функция потерь (1D):

$$Q(w_0, w_1, \mathbb{D}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (w_1 x_i + w_0 - y_i)^2$$

Частные производные:

$$\frac{\partial Q}{\partial w_1} = \frac{2}{\ell} \sum_{i=1}^{\ell} (w_1 x_i + w_0 - y_i) x_i$$

Шаг обновления:

$$w_j^t = w_j^{t-1} - \eta_t \frac{\partial Q}{\partial w_j} (w^{t-1}, \mathbb{D})$$




Stochastic Gradient Descent (SGD)

GD: Вычисляет шаг, используя *всю обучающую выборку*. Точно, но долго и требует много памяти.

SGD: Выбирает небольшую группу объектов (mini-batch) и обновляет веса только по нему.

Особенности SGD:

- Шаг выполняется значительно быстрее;
- Траектория спуска получается "шумной";
- Шум помогает "выпрыгивать" из локальных минимумов.





Метрики качества регрессии

MAE (Mean Absolute Error): Менее чувствительна к выбросам.

$$MAE = \frac{1}{\ell} \sum_{i=1}^{\ell} |a(x_i) - y_i|$$

MSPE: Штрафует за сильные отклонения в процентах.

$$MSPE = \frac{1}{\ell} \sum_{i=1}^{\ell} \left(\frac{y_i - a(x_i)}{y_i} \right)^2$$

R^2 (Козф. детерминации): Доля объясненной дисперсии. Идеал $R^2 = 1$.

$$R^2 = 1 - \frac{\sum_{i=1}^{\ell} (a(x_i) - y_i)^2}{\sum_{i=1}^{\ell} (y_i - \bar{y})^2}$$



Теорема Гаусса-Маркова

ошибки не носят систематического характера: $\mathbb{E}(\varepsilon_i | x_i) = 0 \quad \forall i$;

дисперсия ошибок одинакова (гомоскедастичность): $\mathbb{D}(\varepsilon_i) = \sigma^2 \quad \forall i$;

ошибки некоррелированы: $cov(\varepsilon_i, \varepsilon_j) = 0 \quad \forall i \neq j$.

Оценки метода наименьших квадратов (МНК) оптимальны в классе линейных несмещённых оценок.

Простыми словами: **мы получили наилучшую возможную оценку для параметра w .** Именно она и используется для аналитического решения.



Машинное обучение

Спасибо за внимание!

Вопросы?

Докладчик: Иван Горохов